

平成28年度NGSハンズオン講習会 RNA-seq解析

2016年7月27日

amelieff

本講義にあたつて

- 代表的な解析の流れを紹介します。
 - 論文でよく使用されているツールを使用します。
- コマンドを沢山実行します。
 - タイプミスが心配な方は、コマンド例がありますのでコピーして実行してください。
 - 実行が遅れてもあせらずに、課題や休憩の間に追い付いてください。

本講義の内容

前半パート（講義）

- RNA-seqとは
- RNA-seq解析の流れ
- 公開データの取得
- クオリティコントロール
- マッピング
- 発現定量

後半パート（実習）

- クオリティコントロール
- マッピング
- 発現定量
- 発現比較
- 可視化
- まとめ


前半パート（講義）

RNA-seqとは

- メッセンジャーRNA (mRNA) をキャプチャして次世代シーケンサーでシーケンシングする手法
- リファレンスがある生物種の場合：
 - 既知遺伝子にマッピングする
 - リファレンスにマッピングして遺伝子発現量を定量する
- リファレンスがない生物種の場合：
 - アセンブリングして転写物構造を予測し、それに対してマッピングする
 - 近いゲノムのリファレンスにマッピングする

クオリティコントロール


PolyA/T tailの混入



RNA-seq (mRNA) では
3'末端にPolyA/T tailが
ついている転写物を
シーケンシングするため、
リードには、PolyA/T tail
が存在する

RNA-seq解析の流れ

解析ソフト例



- RNA-seq解析の一般的な流れであり、全てのRNA-seqで同一の解析を行うわけではありません。
- 研究の目的やデータに合わせて、最適な解析を行います。

公開データの取得

今回の解析に必要なデータ

■ リファレンスゲノム (実行済み)

- http://support.illumina.com/sequencing/sequencing_software/igenome.html

The screenshot shows the Illumina website with a search bar at the top. Below it, a table lists genome builds for *Saccharomyces cerevisiae* (Yeast). The table includes columns for Ensembl, NCBI, UCSC, and two specific builds: R64-1-1 and EF4. The build R64-1-1 is circled in green.

	Ensembl	R64-1-1	EF4
Saccharomyces cerevisiae (Yeast)	NCBI UCSC	build3.1 sacCer3	build2.1 sacCer2

■ 解析対象のシークエンスデータ (実行済み)

The screenshot shows the DDBJ Sequence Read Archive (DRA) homepage. At the top, there is a logo for DDBJ (DNA Data Bank of Japan) and a search bar with a Google Custom Search placeholder. Below the search bar, there is a navigation menu with links to Home, Handbook, FAQ, Search, Download, Pipeline, and About DRA. A "News" section is visible, featuring a recent update about a new D-way registration interface.

News

2016年06月01日 **New:** D-way 登録インターフェースの更新

DDBJ Sequence Read Archive (DRA) は Roche 454 GS System®, Illumina Genome Analyzer®, Applied Biosystems SOLiD® Systemなどの次世代シークエンサからの出力データのためのデータベースです。DRA は International Nucleotide Sequence Database Collaboration (INSDC) のメンバーであり、NCBI Sequence Read Archive (SRA) と EBI Sequence Read Archive (ERA) との国際協力のもと、運営されています。従来のキャピラリ式シークエンサからの出力データは DDBJ Trace Archive にご登録ください。

公開データの取得

酵母のリファレンスゲノムデータの取得方法

```
$ wget ftp://igenome:G3nom3s4u@ussd-
  ftp.illumina.com/Saccharomyces_cerevisiae/NCBI/build3.1/Saccha-
  romyces_cerevisiae_NCBI_build3.1.tar.gz
$ tar zxvf Saccharomyces_cerevisiae_NCBI_build3.1.tar.gz
```

Saccharomyces cerevisiaeのリファレンスゲノムをイルミナのWebページからダウンロードし解凍する (実行済み)。

```
$ ls -l /home/iu/genome/sacCer3/
:
-rwxr-xr-x. 1 iu iu 12400379 5月 23 11:09 genome.fa
:
-rwxr-xr-x. 1 iu iu       462  5月 23 11:09 genome.fa.fai
:
```

/home/iu/genome/sacCer3/に
解凍したファイル（今回使用するデータのみ）を置いてあるので確認する。

公開データの取得

fastaファイルの中身の確認

```
$ less /home/iu/genome/sacCer3/genome.fa  
>chrI  
CCACACCACACCCACACACACACACACACACACACACACACACACACAC  
CACACACACACATCCTAACACTACCCTAACACAGGCCCTAATCTAACCCCTG  
GCCAACCTGTCTCTCAACTTACCCCTCCATTACCCCTGCCTCCACTCGTTAC  
CCTGTCCCATTCAACCATAACCACTCCGAACCACCATCCATCCCTCTACTT  
ACTACCACTCACCCACCGTTACCCCTCCAATTACCCATATCCAACCCACTG  
:
```

1行目： コンティグ名

2行目以降： 実際の配列情報

※「q」で閲覧を終了する

公開データの取得

解析対象のシーケンスデータの取得方法 ①

<http://trace.ddbj.nig.ac.jp/dra/index.html>へアクセスする。

The screenshot shows the DDBJ Sequence Read Archive (DRA) homepage. At the top left is the DDBJ logo (a stylized orange 'S' and 'D') with the text 'DNA Data Bank of Japan'. At the top right are links for 'Login & Submit', 'Databases', 'English', and 'Contact'. Below the header is a search bar containing 'Google™ カスタム検索' and a magnifying glass icon. The main navigation menu below the search bar includes 'Home', 'Handbook', 'FAQ', 'Search' (which is highlighted with a green oval), 'Download', 'Pipeline', and 'About DRA'. To the left of the menu, the text 'Sequence Read Archive' is in orange, and 'click!!' is in green. A horizontal line separates the header from the main content area.

News

2016年06月01日 **New:** D-way 登録インターフェースの更新

DDBJ Sequence Read Archive (DRA) は Roche 454 GS System®, Illumina Genome Analyzer®, Applied Biosystems SOLiD® System などの次世代シーケンサからの出力データのためのデータベースです。DRA は International Nucleotide Sequence Database Collaboration (INSDC) のメンバーであり、NCBI Sequence Read Archive (SRA) と EBI Sequence Read Archive (ERA) との国際協力のもと、運営されています。従来のキャピラリ式シーケンサからの出力データは DDBJ Trace Archive にご登録ください。

公開データの取得

解析対象のシーケンスデータの取得方法 ②
SRP058976を検索する。

DRASearch type!!

Accession :

Organism :

CenterName :


StudyType :

Platform :

Keyword :

Show 20 records Sort by Study

click!!



公開データの取得

解析対象のシーケンスデータの取得方法 ③
研究概要を確認する。

DRA Search

Send Feedback

 Search Home

 DRA Home

SRP058976

Study Detail

Title	RNA Proximity Ligation to Resolve Intramolecular RNA Structures in situ
Study Type	Other
Abstract	Proof-of-concept of a new method involving the limited digestion and subsequent ligation of intramolecular RNA structures in situ followed by deep sequencing Overall design: Proof-of-concept of RPL in S. cerevisiae and H. sapiens tissue culture
Description	
Center Name	GEO

Navigation

 Submission	SRA271046			
 Experiment	SRX1046447			
	SRX1046448			
	SRX1046449			
	SRX1046450			
	SRX1046451			
click!!	SRX1046452			
	SRX1046453			
	SRX1046454			
	SRX1046455			
	SRX1046456			
	SRX1046457			
	SRX1046458			
	SRX1046459			

公開データの取得

解析対象のシーケンスデータの取得方法 ④
実験詳細を確認する。

The screenshot shows the DRA Search interface for experiment SRX1046452. The page has a yellow header bar with the title 'DRA Search' and navigation links for 'Send Feedback', 'Search Home', and 'DRA Home'. Below the header, the experiment ID 'SRX1046452' is displayed along with download icons for 'FASTQ' and 'SRA'. A dashed green arrow points from the 'SRA' icon down to the 'Library Description' section. Another dashed green arrow points from the 'SRA' icon in the 'Navigation' sidebar down to the 'Download' link in the same sidebar.

Experiment Detail	
Title	GSM1701707: RPL_yeast_imidazole_ligase; <i>Saccharomyces cerevisiae</i> ; OTHER
Design Description	
Organism	<i>Saccharomyces cerevisiae</i>

Library Description	
Name	
Strategy	OTHER
Source	TRANSCRIPTOMIC
Selection	other
Layout	PAIRED
Orientation	
Nominal Length	
Nominal Sdev	
Construction Protocol	RNA was extracted using TRIzol and Zymo DirectZOL columns Illumina TruSeq

Navigation	
Submission	SRA271046
Study	SRP058976
Sample	SRS951223
Run	SRR2048224

ここからダウンロード可能

公開データの取得

解析対象のシーケンスデータの取得方法 ⑤
データをダウンロードする(実行済み)。

```
$ mkdir -p rnaseq/data
```

解析を行うrnaseqディレクトリとdataディレクトリを作成する。

```
$ cd rnaseq/data/  
$ wget ¥  
ftp://ftp.ddbj.nig.ac.jp/ddbj_database/dra/sralite/ByExp/lites  
ra/SRX/SRX104/SRX1046452/SRR2048224/SRR2048224.sra
```

SRR2048225、SRR2048228、SRR2048229についても同様にダウンロード

- SRR2048224 : RPL_yeast_imidazole_ligase
- SRR2048225 : RPL_yeast_imidazole_ligase_rep2
- SRR2048228 : RPL_yeast_imidazole_noligase
- SRR2048229 : RPL_yeast_imidazole_noligase_rep2

公開データの取得

解析対象のシーケンスデータの取得方法 ⑥

SRAデータをFASTQファイルへ変換する(実行済み)。

```
$ fastq-dump --split-files SRR2048229.sra
```

fastq-dumpコマンドは、NCBI SRA toolkit をインストールすると利用できる。

```
$ head -40000 SRR2048224_1.fastq > 10K_SRR2048224_1.fastq
```

```
$ head -40000 SRR2048224_2.fastq > 10K_SRR2048224_2.fastq
```

先頭1万リードを抽出する(実行済み)。SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

```
$ ls data
```

```
10K_SRR52048224_1.fastq 10K_SRR52048228_1.fastq
```

```
10K_SRR52048224_2.fastq 10K_SRR52048228_2.fastq
```

```
10K_SRR52048225_1.fastq 10K_SRR52048229_1.fastq
```

```
10K_SRR52048225_2.fastq 10K_SRR52048229_2.fastq
```

公開データの取得

解析対象のシーケンスデータの取得方法 ⑦
シーケンスデータを確認する。

```
$ less data/10K_SRR2048224_1.fastq
```

```
@SRR2048224.1 NS500272:29:H2KGHBGXX:1:1101:4753:1025 length=80
NTGGTNCCGAAGCTCCACTTATTCTACACCCTCTATGTCTTCACAATGTCAAAGTAGAGTC
AAGCTAACAGGGTCT
+SRR2048224.1 NS500272:29:H2KGHBGXX:1:1101:4753:1025 length=80
#AAAAA#FFFFFFFFFFFFFFFFFF<FFFFFFFFFFFFFFFFFFFAFFFFF
FAFFFFF.FFFFFFFF
:
```

fastqファイルの中身を表示する。

- 1行目： @配列IDと付加情報
- 2行目： 塩基配列
- 3行目： +配列IDと付加情報
- 4行目： クオリティ

※ fastqファイルは1リードあたり4行で表記される。

公開データの取得

解析対象のシーケンスデータの取得方法 ⑧
リード数を確認する。

```
$ wc -l data/10K_SRR2048224_1.fastq  
40000 data/10K_SRR2048224_1.fastq
```

40,000行が抽出されていることを確認する。

```
$ wc -l data/10K_SRR2048224_2.fastq  
40000 data/SRR2048224_2.fastq
```

1リードは4行なので、リード数は $40,000 / 4 = 1万$ リードである。

```
$ wc -l data/*
```

ワイルドカード (*) でまとめて確認できる。

クオリティコントロール

FastQC：シーケンスクオリティチェックソフトウェア

```
$ fastqc -v
```

```
FastQC v0.10.1
```

バージョンを確認する (最新版はv0.11.5)。

```
$ fastqc -h
```

```
FastQC - A high throughput sequence QC analysis tool
```

SYNOPSIS

```
fastqc seqfile1 seqfile2 .. seqfileN
```

```
fastqc [-o output dir] [--(no)extract] [-f fastq|bam|sam]  
[-c contaminant file] seqfile1 .. seqfileN  
:
```

.fastq以外に.samや.bamも指定可能、複数ファイルの指定も可能である。

クオリティコントロール

FastQCの実行

```
$ mkdir fastqc_res  
$ fastqc -o fastqc_res -f fastq --nogroup ¥  
  data/10K_SRR2048224_1.fastq data/10K_SRR2048224_2.fastq  
$ ls fastqc_res  
10K_SRR2048224_1_fastqc      10K_SRR2048224_2_fastqc  
10K_SRR2048224_1_fastqc.zip  10K_SRR2048224_2_fastqc.zip
```

解析結果のhtmlファイルをブラウザ (firefox)で確認する。

```
$ firefox ¥  
fastqc_res/10K_SRR2048224_1_fastqc/fastqc_report.html ¥  
fastqc_res/10K_SRR2048224_2_fastqc/fastqc_report.html
```

WEBブラウザ上で、クオリティチェックの解析結果が確認できる。

SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

クオリティコントロール

FastQCの結果確認 ①

Summary

-  [Basic Statistics](#)
-  [Per base sequence quality](#)
-  [Per sequence quality scores](#)
-  [Per base sequence content](#)
-  [Per base GC content](#)
-  [Per sequence GC content](#)
-  [Per base N content](#)
-  [Sequence Length Distribution](#)
-  [Sequence Duplication Levels](#)
-  [Overrepresented sequences](#)
-  [Kmer Content](#)



Basic Statistics

Measure	Value
Filename	10K_SRR2048224_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	10000
Filtered Sequences	0
Sequence length	80
%GC	45

Basic Statistics

ファイルの基本的な情報。ファイルタイプや、リード数、リード長などの情報が表示される。ここではwarning, failureは出ない。

クオリティコントロール


FastQCの結果確認 ②

Per Base Sequence Quality

横軸はリード長、縦軸はquality valueを表す。

リードの位置における全体のクオリティの中央値や平均を確認できる。赤線は中央値、青線は平均値、黄色のボックスは25%～75%の領域を表す。上下に伸びた黒いバーが10%～90%の領域を意味する。


 Per base sequence quality



クオリティコントロール

FastQCの結果確認 ③

✓ Per sequence quality scores



Per Sequence Quality Scores
縦軸がリード数、横軸がPhred quality scoreの平均値。

クオリティコントロール


FastQCの結果確認 ④

Per Base Sequence Content

リードにおける位置での各塩基の割合を示す。

いずれかの位置で、AとTの割合の差、もしくはGとCの割合の差が10%以上だとwarning, 20%以上でfailureとなる。


✖ Per base sequence content



クオリティコントロール

FastQCの結果確認 ⑤

⚠ Per sequence GC content



Per Base GC Content

リードにおける位置でのGC含量を表す。

いずれかの位置で、全体でのGC含量の平均値より5%以上の差が開くとwarning, 10%でfailureとなる。


クオリティコントロール

FastQCの結果確認 ⑥

Per Base N Content

“N”はシーケンサーの問題でATGCいずれの塩基にも決定出来なかった場合に記述される。リードのいずれかの位置で5%以上Nが存在するとwarning, 20%以上でfailureとなる。


Per base N content



クオリティコントロール

FastQCの結果確認 ⑦

Sequence Length Distribution




Sequence Length Distribution
リード長の全体の分布。
全てのリードの長さが同じであることを前提としており、一定でなければwarning、ゼロのものが含まれているとfailureになる。

クオリティコントロール

FastQCの結果確認 ⑧

✖ Sequence Duplication Levels



Sequence Duplication Levels
リードの重複レベルを見ている。
1～10はそれぞれ重複のレベルで、
全体の20%以上がユニークでないものだとwarning, 50%以上がユニークでないとfailureとなる。

クオリティコントロール

FastQCの結果確認 ⑨

⚠ Overrepresented sequences

Sequence	Count	Percentage	Possible Source
CTCAAACTTCCATCGGCTTGAAACCGATA GTCCCTCTAAGAAGTGGATAA	89	0.89	No Hit
CTAACGTCTATGCGAGTGTTGGGTGAAACCCATACCGTAATGAAAG	43	0.43	No Hit
CTAACTTCGTTCTGATTAATGAAAACGCTTGGCAAATGTTTCGCA	42	0.42	No Hit
CAGGTCCAGACACAATAAGGATTGACAGATTGAGAGCTTTCTGATT	40	0.4	No Hit
CAGAAAGTGTGTTGACGCAATGTGATTTCTGCCAGTGCTGAATGTC	37	0.37	No Hit
CTCTTTCAAAGTTCTTTCATCTTCCATCACTGTACTTGTGCTATC	36	0.36	No Hit
GCTGAACCTAACGATATCAATAAGCGGAGGAAAGAAACCAACCGGGATT	36	0.36	No Hit
ACCAGGTCCAGACACAATAAGGATTGACAGATTGAGAGCTTTCTGAT	33	0.33	No Hit
CTCACCGGTCCAGACACAATAAGGATTGACAGATTGAGAGCTTTCTT	32	0.32	No Hit
CCAGAACCCAAAGACTTTGATTTCTGTAAGGTCCGAGTGGGTCAATTAA	31	0.31	No Hit
CTTCCCTTCAACAATTTCACGTACTTTCACTCTTTCAAGTTCT	29	0.29	No Hit
CCCTGTGTAACCTTCTGGCACCTCTAGCCTCAATTCCGAGGGACTAA	29	0.29	No Hit
CTAAGGGGGCTCATGGAGAACAGAAATCTCAGTAGAACAAAAGGGTAA	28	0.2799999999999997	No Hit
CTGCCAGTAGTCATATGCTTGCTCAAAGATTAGCCATGCATGTCTAAG	27	0.27	No Hit
CTCTTTCAAAGTTCTTTCATCTTCCATCACTGTACTTGTGCTA	26	0.26	No Hit
CTGAACCTAACGATATCAATAAGCGGAGGAAAGAAACCAACCGGGATTG	25	0.25	No Hit
CTCAAACAGGCATGCCCTGGATACCAAGGGCGCAATGTGCGTTCAA	24	0.24	No Hit

Overrepresented Sequences

重複している配列とその割合を表す。特定の配列が全リードの0.1%を超えるとwarning、1%を超えるとfailureとなる。

クオリティコントロール

PRINSEQ : クオリティコントロールソフトウェア

PRINSEQ

[Home](#) [FAQ](#) [Manual](#) [Downloads](#) [SF Project Page](#) [Use PRINSEQ](#)

Easy and rapid quality control and data preprocessing.

PRINSEQ can be used to filter, reformat, or trim your genomic and metagenomic sequence data. It generates summary statistics of your sequences in graphical and tabular format. It is easily configurable and provides a user-friendly interface.



<http://prinseq.sourceforge.net>

機能

- PolyA/T tailの除去
- クオリティが低いリード末端のトリミング
- 配列長が短いリードの除去
- 片側のみのリードの除去

クオリティコントロール

PRINSEQのインストール(実行済み)

```
$ wget ¥  
https://sourceforge.net/projects/prinseq/files/standalone/prin  
seq-lite-0.20.4.tar.gz #ソースコードをダウンロード  
$ tar zxvf prinseq-lite-0.20.4.tar.gz #展開  
$ cd prinseq-lite-0.20.4 #プログラムの入っているディレクトリに移動  
$ chmod +x prinseq-lite.pl #実行権限を付与  
$ ln -s /path/to/prinseq-lite-0.20.4/prinseq-lite.pl ¥  
/usr/local/bin #PATHを通す
```

PRINSEQの使い方の確認

```
$ prinseq-lite.pl -h
```

マッピング

HISAT2：マッピングソフトウェア

<http://ccb.jhu.edu/software/hisat2/index.shtml>

特徴

- スプライシングを考慮してゲノム配列にマッピングする
- TopHat2よりも精度・速度ともに向上している
- メモリ消費量が少ない

Table 1 | Sensitivity and precision of leading spliced aligners

Program	No. of splice sites reported	No. of true splice sites reported	Sensitivity (%)	Precision (%)
HISATx1	91,904	85,546	97.3	93.1
HISATx2	90,331	85,603	97.3	94.8
HISAT	90,300	85,587	97.3	94.8
STAR	95,892	84,678	96.3	88.3
STARx2	92,254	84,734	96.3	91.8
GSNAP	92,547	85,598	97.3	92.5
OLego	86,779	82,879	94.2	95.5
TopHat2	96,474	79,705	90.6	82.6

Table 2 | Run times and memory usage for HISAT and other spliced aligners

Program	Run time (min)	Memory usage (GB)
HISATx1	22.7	4.3
HISATx2	47.7	4.3
HISAT	26.7	4.3
STAR	25	28
STARx2	50.5	28
GSNAP	291.9	20.2
OLego	989.5	3.7
TopHat2	1,170	4.3

Kim et al., Nature Methods, 2015

マッピング

HISAT2のインストール(実行済み)

```
$ wget ¥  
  ftp://ftpccb.jhu.edu/pub/infphilo/hisat2/downloads/hisat2-  
  2.0.4-Linux_x86_64.zip #ソースコードをダウンロード  
$ unzip hisat2-2.0.4-Linux_x86_64.zip #展開  
$ ln -s /path/to/hisat2-2.0.4/hisat2 /usr/local/bin #PATHを通す
```

マッピング

HISAT2のIndexファイルのダウンロード(実行済み)

```
$ wget ftp://ftp.ccb.jhu.edu/pub/infphilo/hisat2/data/sc3.tar.gz  
$ tar zxvf sc3.tar.gz  
$ ls /home/iu/genome/sacCer3/Hisat2Index/  
genome.1.ht2  genome.3.ht2  genome.5.ht2  genome.7.ht2  
genome.2.ht2  genome.4.ht2  genome.6.ht2  genome.8.ht2
```

HISAT2の使い方の確認

```
$ hisat2 -h  
HISAT2 version 2.0.4 by Daehwan Kim (infphilo@gmail.com,  
www.ccb.jhu.edu/people/infphilo)  
Usage:hisat2 [options]* -x <ht2-idx> {-1 <m1> -2 <m2> | -U <r> |  
--sra-acc <SRA accession number>} [-S <sam>]  
:
```

発現定量

遺伝子の発現量 ≠ 遺伝子上にマップされたリード数

- 長い遺伝子ほどマップされるリードは多くなる（遺伝子間のバイアス）
- サンプル量の多いランほどマップされるリードは多くなる（ラン間のバイアス）

→ これらのバイアスを補正してから発現量を比較する必要がある

- 発現量としてよく使われる指標

RPKM (Reads Per Kilobase per Million mapped reads)

FPKM (Fragments Per Kilobase of exon per Million mapped fragments)

どちらも、発現量をエクソン長と全マッピング数で補正した値

発現定量

Cufflinks : 遺伝子発現解析ソフトウェア

<http://cole-trapnell-lab.github.io/cufflinks>

cufflinksの使い方の確認

```
$ cufflinks
cufflinks v2.2.1
linked against Boost version 105400
-----
Usage:  cufflinks [options] <hits.sam>
General Options:
  -o/--output-dir  write all output files to this directory
  -p/--num-threads number of threads used during analysis
  --seed           value of random number generator seed
  -G/--GTF         quantitate against reference transcript annotations
  -g/--GTF-guide   use reference transcript annotation to guide assembly
  -M/--mask-file   ignore all alignment within transcripts in this file
  :
```

-g : アセンブルのガイドとして既知の遺伝子情報を使用することができる。

その他のRNA-seq解析

■ リファレンスがある生物種の場合 :

- SNP・InDel検出 (GATK, freebays)
- 融合遺伝子検出 (Chimerascan, TopHat-Fusion)
- circular RNA検出 (DCC, CIRI)
- シングルセルRNA解析 (Cell Ranger (10x Genomics))


■ リファレンスがない生物種の場合 :

- De novoアセンブリ (Trinity)

後半パート（実習）


RNA-seq解析の実行

本講義でご紹介するパイプライン



RNA-seq解析の実行

本講義でご紹介するパイプライン



クオリティコントロール

PRINSEQによるクオリティコントロール

```
$ mkdir 1_qc  
$ prinseq-lite.pl -fastq data/10K_SRR2048224_1.fastq ¥  
  -fastq2 data/10K_SRR2048224_2.fastq ¥  
  -out_good 1_qc/10K_SRR2048224.notail ¥  
  -out_bad null -out_format 3 -trim_left 5 -trim_tail_right 5 ¥  
  -trim_qual_right 30 -ns_max_p 20 -min_len 30
```

- fastq 入力のFASTQファイル
- fastq2 入力のFASTQファイル（ペアエンドの場合）
- out_good フィルターを通過したリードの名前
- out_bad フィルタリングされたリードの名前（nullは出力しない）
- out_format 1 (FASTA only), 2 (FASTA and QUAL), 3 (FASTQ),
4 (FASTQ and FASTA), or 5 (FASTQ, FASTA and QUAL)

クオリティコントロール

PRINSEQによるクオリティコントロール

```
$ mkdir 1_qc  
$ prinseq-lite.pl -fastq data/10K_SRR2048224_1.fastq ¥  
-fastq2 data/10K_SRR2048224_2.fastq ¥  
-out_good 1_qc/10K_SRR2048224.notail ¥  
-out_bad null -out_format 3 -trim_left 5 -trim_tail_right 5 ¥  
-trim_qual_right 30 -ns_max_p 20 -min_len 30
```

SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

-trim_tail_right

3'末端のポリテールが5以上の末端を除去

-trim_qual_right

3'末端からクオリティ30以下の塩基を除去

-ns_max_p

未知の塩基(N)が多いリード除去 (20%以上)

-min_len

配列長が短いリード除去 (30bp以下)

PRINSEQは極めて多機能なソフトウェアであり、クオリティチェックからトリミング、フィルタリングまで様々なプロセスが可能

クオリティコントロール

FastQCの実行

```
$ fastqc -o fastqc_res -f fastq --nogroup ¥  
1_qc/10K_SRR2048224.notail_1.fastq ¥  
1_qc/10K_SRR2048224.notail_2.fastq
```

解析結果のhtmlファイルをブラウザ (firefox)で確認する。

```
$ firefox fastqc_res/10K_SRR2048224.notail_1_fastqc.html
```



Basic Statistics

Measure	Value
Filename	10K_SRR2048224_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	10000
Filtered Sequences	0
Sequence length	80
%GC	45

クリーニング前



Basic Statistics


Measure	Value
Filename	10K_SRR2048224.notail_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	9992
Filtered Sequences	0
Sequence length	46-75
%GC	45

クリーニング後


クオリティコントロール

リードクオリティの確認

✓ Per base sequence quality



✓ Per base sequence quality



クリーニング前




クリーニング後


クオリティコントロール

各塩基の含有率の確認

✖ Per base sequence content



✖ Per base sequence content



クリーニング前



クリーニング後

RNA-seq解析の実行

本講義でご紹介するパイプライン






マッピング

HISATのアルゴリズム

特徴

- スプライシングを考慮してゲノム配列にマッピングする
- hierarchical indexingを用いることで高速で高感度のアライメントが可能



Kim et al., Nature Methods, 2015

マッピング

```
$ mkdir 2_mapping  
$ hisat2 -x /home/iu/genome/sacCer3/Hisat2Index/genome --dta ¥  
--dta-cufflinks -1 1_qc/10K_SRR2048224.notail_1.fastq ¥  
-2 1_qc/10K_SRR2048224.notail_2.fastq ¥  
-S 2_mapping/10K_SRR2048224.sam
```

--dta マッピング結果からアセンブリを行う

--dta-cufflinks cufflinksのためのアセンブリを行う

-S SAMファイルに書き出す名前

SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

マッピング

```
$ mkdir 2_mapping  
$ hisat2 -x /home/iu/genome/sacCer3/Hisat2Index/genome --dta ¥  
--dta-cufflinks -1 1_qc/10K_SRR2048224.notail_1.fastq ¥  
-2 1_qc/10K_SRR2048224.notail_2.fastq ¥  
-S 2_mapping/10K_SRR2048224.sam
```

9992 reads; of these:

9992 (100.00%) were paired; of these:

2174 (21.76%) aligned concordantly 0 times

193 (1.93%) aligned concordantly exactly 1 time

7625 (76.31%) aligned concordantly >1 times

2174 pairs aligned concordantly 0 times; of these:

3 (0.14%) aligned discordantly 1 time

2171 pairs aligned 0 times concordantly or discordantly; of these:

4342 mates make up the pairs; of these:

2925 (67.37%) aligned 0 times

99 (2.28%) aligned exactly 1 time

1318 (30.35%) aligned >1 times

85.36% overall alignment rate

マッピング

SAMファイルをBAMファイルに変換

```
$ samtools view -b 2_mapping/10K_SRR2048224.sam > 2_mapping/10K_SRR2048224.bam  
$ ls -lh
```

```
-rw-rw-r-- 1 iu iu 1.7M 5月 31 13:52 2016 10K_SRR2048224.bam  
-rw-rw-r-- 1 iu iu 13M 5月 31 14:54 2016 10K_SRR2048224.sam
```

13MのSAMファイルが1.7Mのバイナリファイルに変換される。

BAMファイルをソート

```
$ samtools sort 2_mapping/10K_SRR2048224.bam -o 2_mapping/10K_SRR2048224.sorted.bam  
$ ls
```

```
10K_SRR2048224.bam 10K_SRR2048224.sorted.bam  
10K_SRR2048224.sam
```

SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

マッピング結果の可視化

BAMファイルのインデックスを作成

```
$ samtools index 2_mapping/10K_SRR2048224.sorted.bam  
$ ls 2_mapping
```


```
10K_SRR2048224.bam  
10K_SRR2048224.sam  
10K_SRR2048224.sorted.bam  
10K_SRR2048224.sorted.bam.bai  
:
```

SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

マッピング結果の可視化

Integrative Genomics Viewer (IGV)を用いた解析結果の確認 ①

```
$ igv.sh
```




IGVを起動し、
Genomesタブから
Load Genomes from
File...を選択。

/home/iu/geno
me/sacCer3の
下にある
genome.faを選
択し開く。

マッピング結果の可視化

Integrative Genomics Viewer (IGV)を用いた解析結果の確認 ②




Fileタブから
Load from File...
を選択。

ソート済みの
bamファイルを
選択し開く。

マッピング結果の可視化


Integrative Genomics Viewer (IGV)を用いた解析結果の確認 ③



サーチウィンドウにchrX:139,767-139,933と入力。

RNA-seq解析の実行

本講義でご紹介するパイプライン



発現定量

cufflinksの実行

```
$ cufflinks -o SRR2048224 --min-frags-per-transfrag 2 ¥  
2_mapping/10K_SRR2048224.sorted.bam  
$ ls SRR2048224
```

```
genes.fpkm_tracking    skipped.gtf  
isoforms.fpkm_tracking transcripts.gtf
```

genes.fpkm_trackingの確認

```
$ less genes.fpkm_tracking
```

4列目にGene ID、10列目にFPKMが記載されている。

SRR2048225、SRR2048228、SRR2048229についても同様に処理する。

発現定量

transcripts.gtf.txtの作成

```
$ vim transcripts.gtf.txt
```

挿入モード (i) で以下を記入

```
SRR2048224/transcripts.gtf  
SRR2048225/transcripts.gtf  
SRR2048228/transcripts.gtf  
SRR2048229/transcripts.gtf
```

挿入モードの終了：エスケープ (ESC)

コマンドモード：コロン (:)


保存：コマンドモードで w + Enter

終了：コマンドモードで q + Enter

保存せずに終了：コマンドモードで q! + Enter

RNA-seq解析の実行

本講義でご紹介するパイプライン



発現比較

cuffmergeの実行

```
$ cuffmerge -o COMPARE ¥  
  -g /home/iu/genome/sacCer3/genes.gtf ¥  
  -s /home/iu/genome/sacCer3/genome.fa ¥  
  transcripts.gtf.txt
```

-o/--output-dir	出力ディレクトリ
-g/--ref-gtf	アノテーション用のgtfファイル
-s/--ref-sequence	リファレンスゲノムFASTAファイル
-p/--num-threads	スレッド数（デフォルト=1）

発現比較

cuffdiffの実行

```
$ cuffdiff -o COMPARE -L Group1,Group2 COMPARE/merged.gtf ¥  
2_mapping/10K_SRR2048224.sorted.bam,¥  
2_mapping/10K_SRR2048225.sorted.bam ¥  
2_mapping/10K_SRR2048228.sorted.bam,¥  
2_mapping/10K_SRR2048229.sorted.bam
```

-o/--output-dir

アノテーション用のgtfファイル

-L/--labels


グループの指定（カンマ区切り）

-p/--num-threads

スレッド数（デフォルト=1）

RNA-seq解析の実行

本講義でご紹介するパイプライン



可視化

cummeRbundの紹介

<http://compbio.mit.edu/cummeRbund/index.html>

Cufflinksの結果を用いて可視化を行うRパッケージ

```
$ R #Cufflinksの実行ディレクトリ (COMPARE) で起動する
> library(cummeRbund)
> cuff <- readCufflinks()
> cuff
```


CuffSet instance with:

2 samples	# サンプル数
6935 genes	# 遺伝子数
7077 isoforms	# 転写産物数
7052 TSS	# 転写開始位置数
6643 CDS	# コード領域数
6935 promoters	# プロモーター数
7052 splicing	# スプライシング領域数
6534 relCDS	# 調節コード領域

可視化

cummeRbundの紹介

```
> s <- csScatter(genes(cuff), "Group1", "Group2", smooth=T)  
> s
```




Scatter Plot
グループ間における
遺伝子発現の偏りを示す


可視化

cummeRbundの紹介

```
> dens <- csDensity(genes(cuff))  
> dens  
> densRep <- csDensity(genes(cuff),replicates=T)  
> densRep
```



グループごとの $\log_{10}(\text{fpkm})$ の分布



サンプルごとの $\log_{10}(\text{fpkm})$ の分布


まとめ

本日行った解析のおさらい。



最後に

本講義でご紹介した流れは、解析方法の一例です。ツールの選択に「正解」はありません。自身のデータに適したツールを選択し、より良い解析手順を確立していってください。



Conesa et al., *Genome Biology*, 2016